Phân tích khám phá dữ liệu (EDA) toàn diện: Data vs Legacy

Notebook này thực hiện EDA song song trên cả 2 nguồn dữ liệu: `data/` (bản mới, chi tiết) và `legacy/` (bản cũ, đầy đủ). Quá trình được thực hiện trên Polars để tối ưu RAM.

In [1]:
```python
# === Cell 1: Imports & Configuration ===
import os
from IPython.display import display, Markdown
import polars as pl
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# Apply seaborn style
sns.set_theme(style="whitegrid")
plt.rcParams['figure.dpi'] = 100

from eda import (
    get_id_coverage,
    analyze_missing_legacy_insights,
    compare_metadata_datasets
)

# Resolve project root
try:
    _THIS_DIR = os.path.dirname(os.path.abspath(__file__))
except NameError:
    _THIS_DIR = os.getcwd()
_PROJECT_ROOT = os.path.dirname(os.path.dirname(_THIS_DIR))
BASE = os.path.join(_PROJECT_ROOT, "data", "raw", "vietnamese-legal-documents")
FILES = {
    "data/content":       os.path.join(BASE, "data", "content.parquet"),
    "data/metadata":      os.path.join(BASE, "data", "metadata.parquet"),
    "data/relationships": os.path.join(BASE, "data", "relationships.parquet"),
    "legacy/content":     os.path.join(BASE, "legacy", "content.parquet"),
    "legacy/metadata":    os.path.join(BASE, "legacy", "metadata.parquet"),
}
```

---

1. Tổng quan Dataset (Schema, Head, Basic Stats)

In [2]:
```python
# === Cell 2: Schema & Size ===
display(Markdown("### 1.1. Cấu trúc và Kích thước các file"))
for name, path in FILES.items():
    if not os.path.exists(path):
        continue
    schema = pl.scan_parquet(path).collect_schema()
```

```
    n_rows = pl.scan_parquet(path).select(pl.len()).collect().item()
    display(Markdown(f"**{name}**: `{n_rows:,}` rows, `{len(schema)}` columns"))
```

1.1. Cấu trúc và Kích thước các file

data/content: `178,665` rows, `2` columns

data/metadata: `153,420` rows, `17` columns

data/relationships: `897,890` rows, `3` columns

legacy/content: `518,235` rows, `2` columns

legacy/metadata: `518,601` rows, `11` columns

In [3]:
```
# === Cell 3: Xem trước dữ liệu ===
display(Markdown("### 1.2. Dữ liệu mẫu (Head)"))
from IPython.display import HTML

for name, path in FILES.items():
    if not os.path.exists(path):
        continue
    display(Markdown(f"**{name}**"))
    df_head = pl.scan_parquet(path).head(3).collect().to_pandas()

    if "title" in df_head.columns:
        display(HTML(
            df_head.style
            .set_properties(**{"white-space": "nowrap"})
            .set_properties(subset=["title"], **{"white-space": "normal", "min-widt
            .set_table_styles([{"selector": "table", "props": [("width", "100%")]}]
            .to_html()
        ))
    else:
        if "content_html" in df_head.columns:
            df_head["content_html"] = df_head["content_html"].str.slice(0, 200) + "
        display(df_head)
```

1.2. Dữ liệu mẫu (Head)

data/content

	id	content_html
0	4260	<table class="detailcontent" width="100%" bord...
1	4266	<table class="detailcontent" width="100%" bord...
2	4262	<table class="detailcontent" width="100%" bord...

data/metadata

	id	title	so_ky_hieu	ng
0	72	Sắc lệnh quy định liên hệ giữa UBKCHC và các cơ quan chuyên môn	103/SL	
1	4260	Về việc chuyển giao nhiệm vụ quản lý Nhà nước về đất lâm nghiệp từ Sở Nông nghiệp và Phát triển Nông thôn và Chi cục kiểm lâm tỉnh sang Sở Địa chính để quản lý	87/1999/QĐ-UB	
2	4280	Về việc quản lý và quy định thống nhất phí chợ trên địa bàn tỉnh Lâm Đồng	157/1999/QĐ-UB	

data/relationships

	doc_id	other_doc_id	relationship
0	4260	10420	Văn bản căn cứ
1	4280	7245	Văn bản căn cứ
2	4263	10420	Văn bản căn cứ

legacy/content

	id	content
0	693036	HỘI ĐỒNG BẦU CỬ QUỐC GIA | CỘNG HÒA XÃ HỘI CH...
1	680604	ỦY BAN NHÂN DÂN TỈNH QUẢNG TRỊ | CỘNG HÒA XÃ ...
2	694312	ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH | CỘNG ...

legacy/metadata

	id	document_number	title
0	693036	115/NQ-HĐBCQG	Nghị quyết 115/NQ-HĐBCQG năm 2026 hướng dẫn xử lý trường hợp khuyết người ứng cử đại biểu Hội đồng nhân dân vì lý do bất khả kháng do Hội đồng bầu cử Quốc gia ban hành
1	680604	34/2025/QĐ-UBND	Quyết định 34/2025/QĐ-UBND năm 2025 quy định khoảng cách và địa bàn làm căn cứ xác định học sinh, học viên không thể đến trường và trở về nhà trong ngày; danh mục trang cấp đồ dùng cá nhân, học phẩm cho học sinh trường phổ thông dân tộc nội trú, cơ sở giáo dục phổ thông được cấp có thẩm quyền giao thực hiện nhiệm vụ giáo dục học sinh dân tộc nội trú trên địa bàn tỉnh Quảng Trị
2	694312	06/2026/QĐ-UBND	Quyết định 06/2026/QĐ-UBND quy định phân cấp quản lý, bảo vệ, thực hiện biện pháp ngăn chặn và xử lý hành vi lấn chiếm đất dành cho đường sắt trên địa bàn Thành phố Hồ Chí Minh

---

2. So sánh Phân bố nhãn (Label Distribution)

In [4]:

```
# === Cell 4: Phân bố loại văn bản & Tình trạng hiệu lực ===
display(Markdown("### 2.1. Phân bố Nhãn (Data vs Legacy)"))

mcmp = compare_metadata_datasets(FILES["data/metadata"], FILES["legacy/metadata"])

# Bảng column mapping
map_rows = [{"data/ (Việt)": k, "legacy/ (Eng)": v} for k, v in mcmp["col_map"].ite
display(Markdown("** 🗓️ Column mapping:**"))
display(pl.DataFrame(map_rows))

meta_summary = [
    {"Metric": "Tổng số dòng", "data/metadata": f'{mcmp["n_data"]:,}', "legacy/meta
    {"Metric": "Số cột", "data/metadata": str(len(mcmp["schema_data"])), "legacy/me
    {"Metric": "Cột chỉ có ở data/", "data/metadata": ", ".join(mcmp["data_only_col
    {"Metric": "Cột chỉ có ở legacy/", "data/metadata": "—", "legacy/metadata": ",
    {"Metric": "ID overlap", "data/metadata": f'{mcmp["n_overlap"]:,}', "legacy/met
    {"Metric": "ID chỉ có ở bộ này", "data/metadata": f'{mcmp["n_only_data"]:,}', "
]
display(pl.DataFrame(meta_summary))

# Categories to always keep even if count < threshold (notable legal types)
_KEEP_ALWAYS = {"Bộ luật", "Hiến pháp", "Constitution", "Code"}
_MIN_COUNT = 300  # hide categories below this threshold

for pair_name, pair_data in mcmp["cat_comparisons"].items():
    display(Markdown(f"### 🏷️ {pair_name}"))

    # For loai_van_ban vs legal_type: filter small categories
    is_type_chart = "loai_van_ban" in pair_name

    filtered_pair = {}
    for side_key, vc_df in [("data", pair_data["data"]), ("legacy", pair_data["lega
        pdf = vc_df.to_pandas()
        if is_type_chart:
            n_before = len(pdf)
            mask = (pdf["count"] >= _MIN_COUNT) | (pdf["value"].isin(_KEEP_ALWAYS))
            pdf = pdf[mask]
            n_hidden = n_before - len(pdf)
        else:
            n_hidden = 0
        filtered_pair[side_key] = (pdf, n_hidden)

    # Dynamic height: scale based on max number of categories across both sides
    n_max = max(len(filtered_pair["data"][0]), len(filtered_pair["legacy"][0]))
    fig_h = max(6, n_max * 0.45 + 2)  # at least 6, ~0.45 inch per category
    fig, axes = plt.subplots(1, 2, figsize=(18, fig_h))

    for i, (label, side_key) in enumerate([("data/", "data"), ("legacy/", "legacy")
        pdf, n_hidden = filtered_pair[side_key]
        pdf = pdf.sort_values("count", ascending=True)
        axes[i].barh(pdf["value"], pdf["count"],
                     color=sns.color_palette("viridis" if i == 0 else "magma", len
        subtitle = f"{label} ({pair_name.split(' vs ')[i]})"
        if n_hidden > 0:
            subtitle += f"  - {n_hidden} hidden types (count < {_MIN_COUNT})"
```

```
        axes[i].set_title(subtitle, fontsize=13, fontweight="bold")
        axes[i].set_xlabel("Count")
        axes[i].tick_params(axis="y", labelsize=9)
        max_cnt = max(pdf["count"])
        for j, (_, row) in enumerate(pdf.iterrows()):
            axes[i].text(row["count"] + max_cnt * 0.01, j,
                         f'{row["count"]:,}', va="center", fontsize=8)
        axes[i].set_xlim(right=max_cnt * 1.15)

    plt.tight_layout()
    plt.show()
```

2.1. Phân bố Nhãn (Data vs Legacy)

🗓️ **Column mapping:**

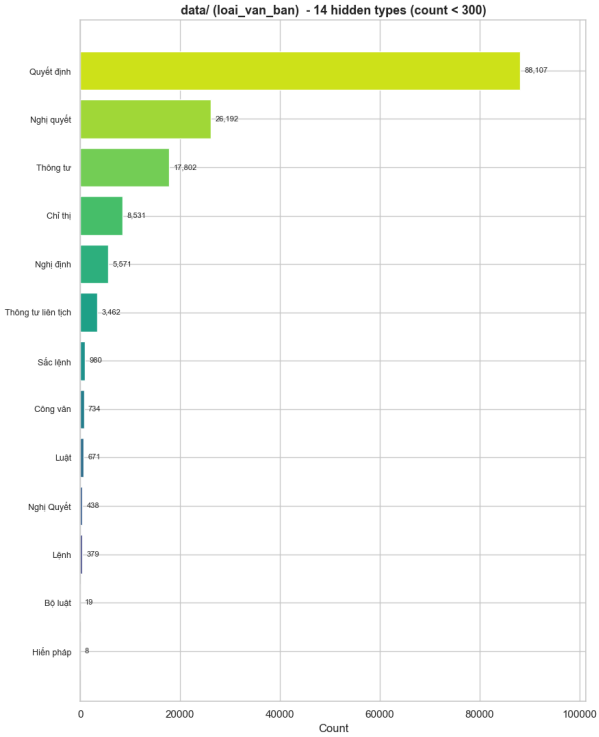
shape: (9, 2)

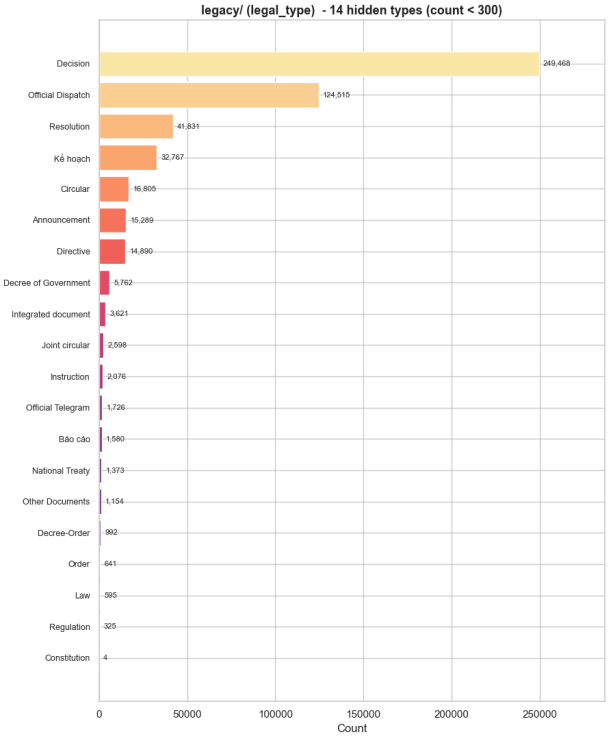
data/ (Việt)	legacy/ (Eng)
str	str
"so_ky_hieu"	"document_number"
"title"	"title"
"loai_van_ban"	"legal_type"
"co_quan_ban_hanh"	"issuing_authority"
"ngay_ban_hanh"	"issuance_date"
"ngay_co_hieu_luc"	"effect_date"
"ngay_het_hieu_luc"	"effectless_date"
"tinh_trang_hieu_luc"	"effect_status"
"nguoi_ky"	"signers"

shape: (6, 3)

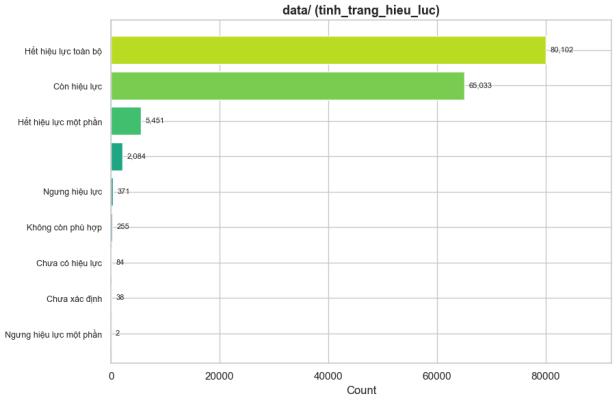
Metric	data/metadata	legacy/metadata
str	str	str
"Tổng số dòng"	"153,420"	"518,601"
"Số cột"	"17"	"11"
"Cột chỉ có ở data/"	"nguon_thu_thap, ngay_dang_cong…	"—"
"Cột chỉ có ở legacy/"	"—"	"legal_sectors"
"ID overlap"	"116,223"	"116,223"
"ID chỉ có ở bộ này"	"37,197"	"402,378"

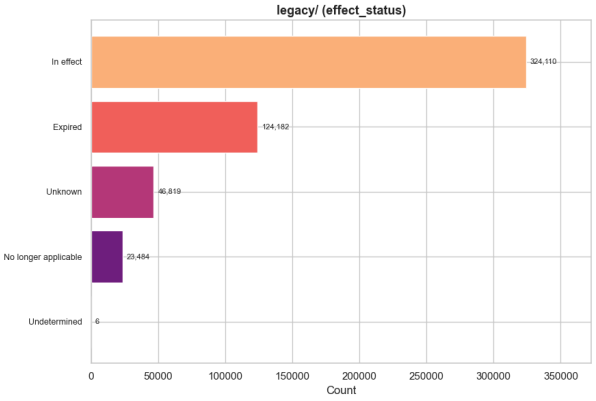
🏷️ loai_van_ban vs legal_type





🏷️ tinh_trang_hieu_luc vs effect_status





---

3. Phân tích Thời gian (Temporal Analysis)

In [5]:
```python
# === Cell 5: So sánh xu hướng ban hành theo năm ===
display(Markdown("### 3.1. So sánh số lượng văn bản qua các năm"))

# Lấy dữ liệu Data
df_time_data = pl.scan_parquet(FILES["data/metadata"]).select("ngay_ban_hanh").coll
parsed_data = df_time_data.with_columns(
    pl.col("ngay_ban_hanh").str.to_date("%d/%m/%Y", strict=False).alias("date")
).filter(pl.col("date").is_not_null())
yearly_data = (
    parsed_data.with_columns(pl.col("date").dt.year().alias("year"))
    .group_by("year").agg(pl.len().alias("count")).sort("year")
    .filter((pl.col("year") >= 1945) & (pl.col("year") <= 2025))
    .to_pandas()
```

```
)

# Lấy dữ liệu Legacy
df_time_legacy = pl.scan_parquet(FILES["legacy/metadata"]).select("issuance_date").
parsed_legacy = df_time_legacy.with_columns(
    pl.col("issuance_date").str.to_date("%Y-%m-%d", strict=False).alias("date")
).filter(pl.col("date").is_not_null())
yearly_legacy = (
    parsed_legacy.with_columns(pl.col("date").dt.year().alias("year"))
    .group_by("year").agg(pl.len().alias("count")).sort("year")
    .filter((pl.col("year") >= 1945) & (pl.col("year") <= 2025))
    .to_pandas()
)

fig, axes = plt.subplots(1, 2, figsize=(16, 5))

# Timeline bar chart overlap
axes[0].plot(yearly_legacy["year"], yearly_legacy["count"], label="Legacy (Tiếng An
axes[0].plot(yearly_data["year"], yearly_data["count"], label="Data (Tiếng Việt)",
axes[0].set_xlabel("Năm ban hành")
axes[0].set_ylabel("Số lượng văn bản")
axes[0].set_title("Xu hướng ban hành văn bản qua các năm")
axes[0].legend()

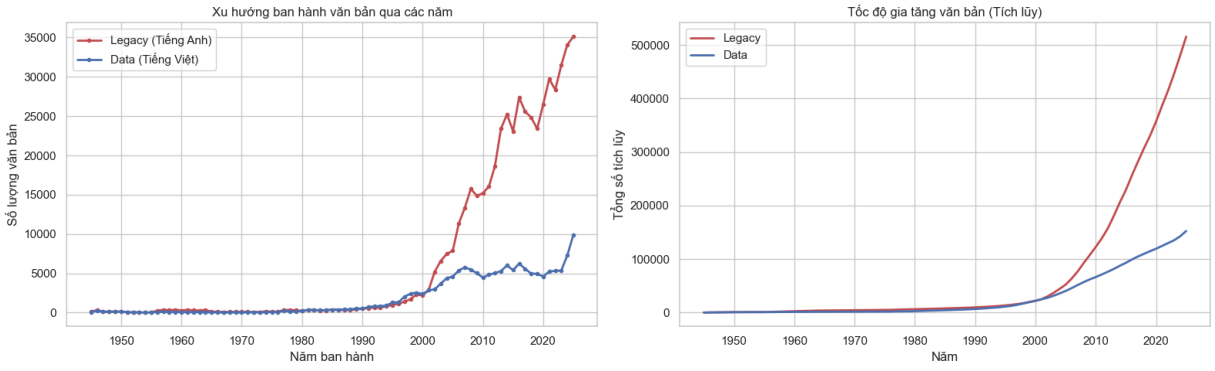
# Cumulative
yearly_data_sorted = yearly_data.sort_values("year")
yearly_data_sorted["cumsum"] = yearly_data_sorted["count"].cumsum()
yearly_legacy_sorted = yearly_legacy.sort_values("year")
yearly_legacy_sorted["cumsum"] = yearly_legacy_sorted["count"].cumsum()

axes[1].plot(yearly_legacy_sorted["year"], yearly_legacy_sorted["cumsum"], label="L
axes[1].plot(yearly_data_sorted["year"], yearly_data_sorted["cumsum"], label="Data"
axes[1].set_xlabel("Năm")
axes[1].set_ylabel("Tổng số tích lũy")
axes[1].set_title("Tốc độ gia tăng văn bản (Tích lũy)")
axes[1].legend()

plt.tight_layout()
plt.show()

display(Markdown("> **Nhận xét**: Tập `legacy` có độ phủ thời gian rộng hơn và lưu
```

3.1. So sánh số lượng văn bản qua các năm



> **Nhận xét**: Tập `legacy` có độ phủ thời gian rộng hơn và lưu trữ nhiều văn bản cũ hơn đáng kể so với `data`.

---

4. Phân tích Top Thực thể (Top Entities)

In [6]:
```
# === Cell 6: Top Cơ quan ban hành & Người ký ===
display(Markdown("### 4.1. So sánh Top Thực thể (Data vs Legacy)"))

fig, axes = plt.subplots(2, 2, figsize=(18, 14))

# -- Cơ quan ban hành --
# Data
auths_data = pl.scan_parquet(FILES["data/metadata"]).select("co_quan_ban_hanh").col
auths_data.columns = ["auth", "count"]
auths_data = auths_data.sort_values("count", ascending=True)
axes[0, 0].barh(auths_data["auth"], auths_data["count"], color="#4C72B0")
axes[0, 0].set_title("Top 15 Cơ quan ban hành (Data)", fontsize=13)

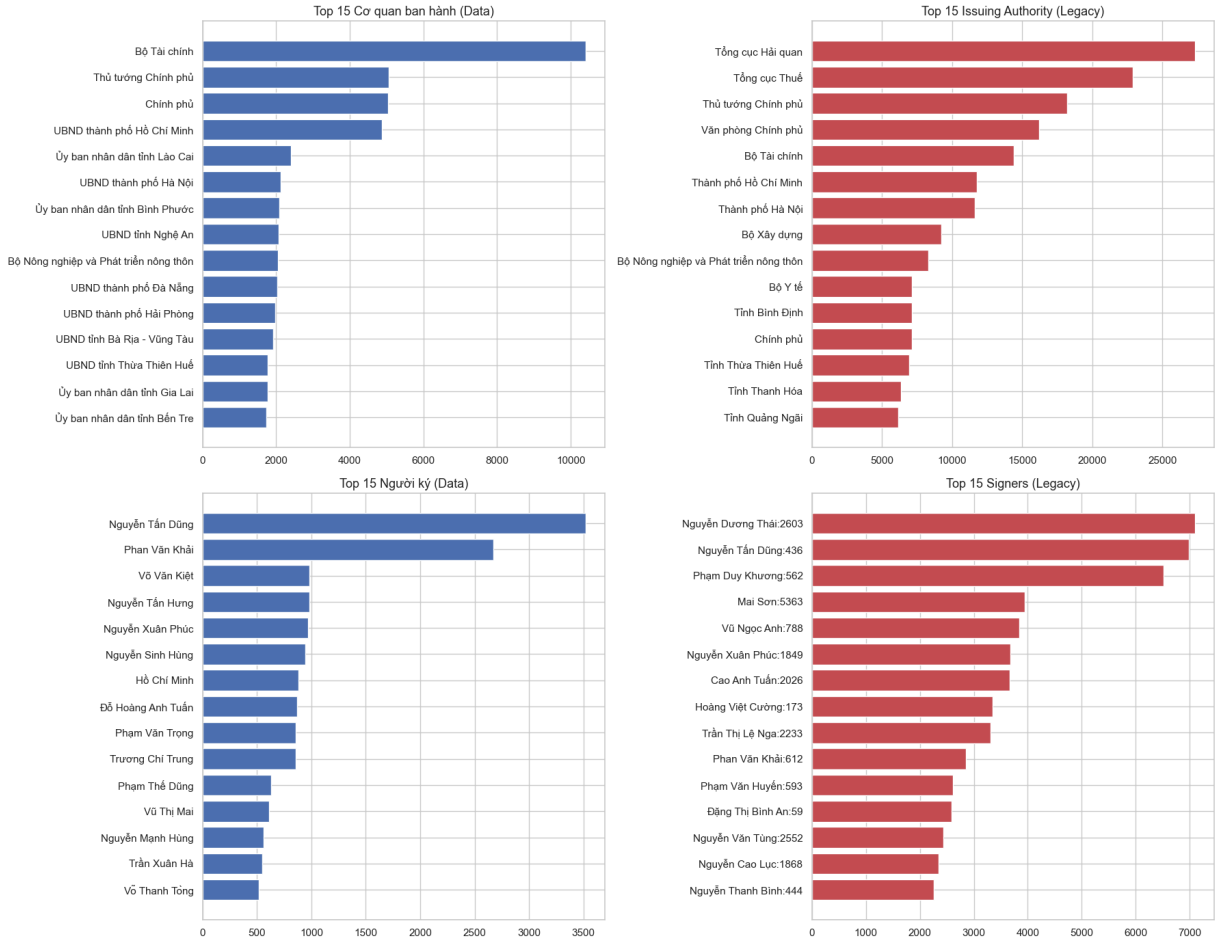
# Legacy
auths_leg = pl.scan_parquet(FILES["legacy/metadata"]).select("issuing_authority").c
auths_leg.columns = ["auth", "count"]
auths_leg = auths_leg.sort_values("count", ascending=True)
axes[0, 1].barh(auths_leg["auth"], auths_leg["count"], color="#C44E52")
axes[0, 1].set_title("Top 15 Issuing Authority (Legacy)", fontsize=13)

# -- Người ký --
# Data
sign_data = pl.scan_parquet(FILES["data/metadata"]).select("nguoi_ky").collect().to
sign_data.columns = ["sign", "count"]
sign_data = sign_data.sort_values("count", ascending=True)
axes[1, 0].barh(sign_data["sign"], sign_data["count"], color="#4C72B0")
axes[1, 0].set_title("Top 15 Người ký (Data)", fontsize=13)

# Legacy
sign_leg = pl.scan_parquet(FILES["legacy/metadata"]).select("signers").collect().to
sign_leg.columns = ["sign", "count"]
sign_leg = sign_leg.sort_values("count", ascending=True)
axes[1, 1].barh(sign_leg["sign"], sign_leg["count"], color="#C44E52")
axes[1, 1].set_title("Top 15 Signers (Legacy)", fontsize=13)

plt.tight_layout()
plt.show()
```

4.1. So sánh Top Thực thể (Data vs Legacy)



---

5. Phân tích Dữ liệu Phi cấu trúc (Unstructured Data)

In [7]:

```
# === Cell 7: So sánh Content Length ===
display(Markdown("### 5.1. So sánh độ dài văn bản (Data HTML vs Legacy Plain Text)"

def get_content_length_stats(path: str, col_name: str):
    len_series = pl.scan_parquet(path).select(pl.col(col_name).str.len_chars().alia
    return len_series

data_len_s = get_content_length_stats(FILES["data/content"], "content_html")
legacy_len_s = get_content_length_stats(FILES["legacy/content"], "content")

# Random sample to plot KDE safely without crashing RAM
data_sample = data_len_s.sample(min(10000, len(data_len_s)), seed=42).to_pandas()
data_sample = data_sample.to_frame(name="length")
data_sample["dataset"] = "data/ (HTML)"

legacy_sample = legacy_len_s.sample(min(10000, len(legacy_len_s)), seed=42).to_pand
legacy_sample = legacy_sample.to_frame(name="length")
legacy_sample["dataset"] = "legacy/ (Plain Text)"

comb_pd = pl.concat([pl.DataFrame(data_sample), pl.DataFrame(legacy_sample)]).to_pa
```

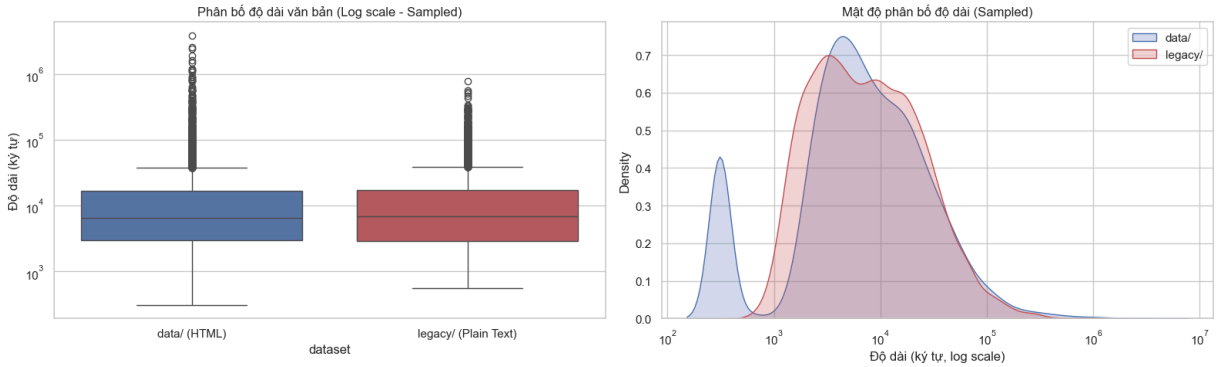
```
fig, axes = plt.subplots(1, 2, figsize=(16, 5))

# Plot 1: Boxplot
sns.boxplot(data=comb_pd, x="dataset", y="length", ax=axes[0], hue="dataset", palet
axes[0].set_yscale("log")
axes[0].set_title("Phân bố độ dài văn bản (Log scale - Sampled)")
axes[0].set_ylabel("Độ dài (ký tự)")

# Plot 2: Histogram KDE
sns.kdeplot(data=data_sample, x="length", log_scale=True, ax=axes[1], color="#4C72B
sns.kdeplot(data=legacy_sample, x="length", log_scale=True, ax=axes[1], color="#C44
axes[1].set_title("Mật độ phân bố độ dài (Sampled)")
axes[1].set_xlabel("Độ dài (ký tự, log scale)")
axes[1].legend()

plt.tight_layout()
plt.show()
```

5.1. So sánh độ dài văn bản (Data HTML vs Legacy Plain Text)



---

6. Kiểm tra Chất lượng Dữ liệu (Data Quality & Coverage)

In [8]:
```
# === Cell 8: Null Heatmap ===
display(Markdown("### 6.1. Tỷ lệ Missing Values (NULL Heatmap)"))

quality_data = {}
for name, path in FILES.items():
    if not os.path.exists(path):
        continue
    schema = pl.scan_parquet(path).collect_schema()
    total_q = pl.scan_parquet(path).select(pl.len()).collect().item()
    null_pcts = {}
    null_exprs = [pl.col(col).null_count().alias(col) for col in schema.names()]
    null_counts = pl.scan_parquet(path).select(null_exprs).collect()
    for col in schema.names():
        null_pcts[col] = round(null_counts[col][0] / total_q * 100, 1)
    quality_data[name] = null_pcts
```

```
# Build matrix
all_cols = []
for v in quality_data.values():
    for c in v:
        if c not in all_cols:
            all_cols.append(c)

matrix = []
ds_labels = []
for ds_name, cols_dict in quality_data.items():
    row = [cols_dict.get(c, float("nan")) for c in all_cols]
    matrix.append(row)
    ds_labels.append(ds_name)

fig, ax = plt.subplots(figsize=(16, 6))
mat = np.array(matrix)
im = ax.imshow(mat, cmap="YlOrRd", aspect="auto", vmin=0, vmax=100)

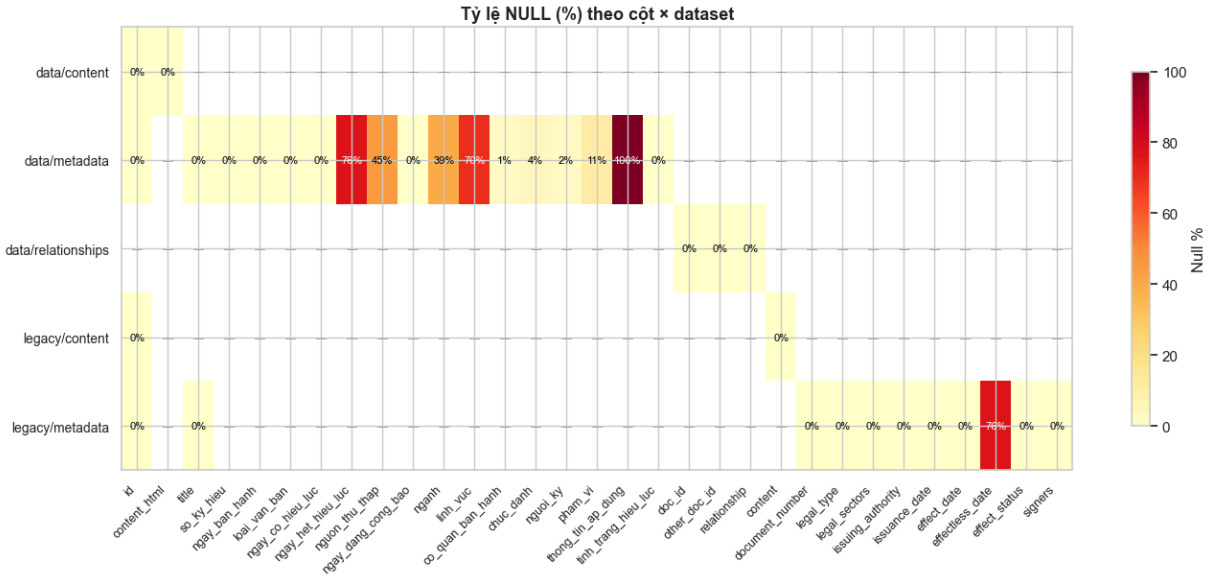
ax.set_xticks(range(len(all_cols)))
ax.set_xticklabels(all_cols, rotation=45, ha="right", fontsize=9)
ax.set_yticks(range(len(ds_labels)))
ax.set_yticklabels(ds_labels, fontsize=10)

# Annotate cells
for i in range(len(ds_labels)):
    for j in range(len(all_cols)):
        val = mat[i, j]
        if np.isnan(val):
            ax.text(j, i, "–", ha="center", va="center", fontsize=8, color="#999")
        else:
            color = "white" if val > 50 else "black"
            ax.text(j, i, f"{val:.0f}%", ha="center", va="center", fontsize=8, colo

plt.colorbar(im, ax=ax, label="Null %", shrink=0.8)
ax.set_title("Tỷ lệ NULL (%) theo cột × dataset", fontsize=13, fontweight="bold")
```

6.1. Tỷ lệ Missing Values (NULL Heatmap)

Out[8]: Text(0.5, 1.0, 'Tỷ lệ NULL (%) theo cột × dataset')



In [9]:
```
# === Cell 9: ID Coverage ===
display(Markdown("### 6.2. Mức độ bao phủ ID (ID Coverage)"))

cov = get_id_coverage(FILES["data/content"], FILES["data/metadata"], FILES["data/re

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Content vs Metadata (data/)
labels1 = ["Only content", "content \u2229 metadata", "Only metadata"]
vals1 = [cov["content_not_in_metadata"], cov["content_in_metadata"], cov["metadata_
colors1 = ["#4C72B0", "#55A868", "#C44E52"]
bars1 = axes[0].bar(labels1, vals1, color=colors1, edgecolor="white", width=0.6)
axes[0].set_title("ID Overlap: data/content vs data/metadata")
axes[0].set_ylabel("Number of IDs")
for bar, v in zip(bars1, vals1):
    axes[0].text(bar.get_x() + bar.get_width()/2, v + max(vals1)*0.02,
                 f"{v:,}", ha="center", fontsize=11, fontweight="bold")

# Legacy content vs metadata
try:
    # Try using Int64 to save memory if possible
    leg_c_raw = pl.scan_parquet(FILES["legacy/content"]).select(pl.col("id")).colle
    try:
        leg_c = set(leg_c_raw.cast(pl.Int64).to_list())
    except:
        leg_c = set(leg_c_raw.to_list())

    leg_m_raw = pl.scan_parquet(FILES["legacy/metadata"]).select(pl.col("id")).coll
    try:
        leg_m = set(leg_m_raw.cast(pl.Int64).to_list())
    except:
        leg_m = set(leg_m_raw.to_list())
except Exception:
    leg_c = set()
    leg_m = set()

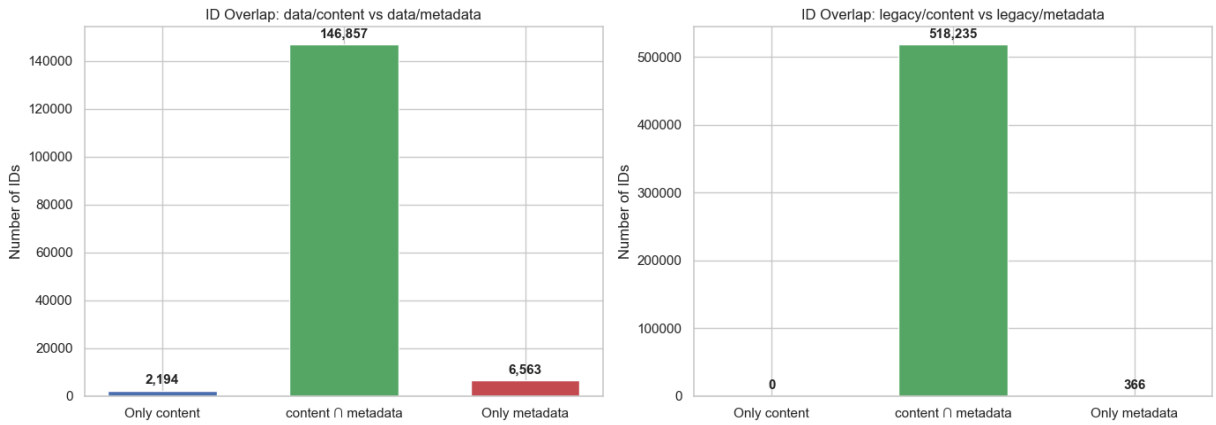
val_c_only = len(leg_c - leg_m)
val_overlap = len(leg_c & leg_m)
```

```
val_m_only = len(leg_m - leg_c)

labels2 = ["Only content", "content \u2229 metadata", "Only metadata"]
vals2 = [val_c_only, val_overlap, val_m_only]
bars2 = axes[1].bar(labels2, vals2, color=colors1, edgecolor="white", width=0.6)
axes[1].set_title("ID Overlap: legacy/content vs legacy/metadata")
axes[1].set_ylabel("Number of IDs")
for bar, v in zip(bars2, vals2):
    axes[1].text(bar.get_x() + bar.get_width()/2, v + max(vals2)*0.02,
                 f"{v:,}", ha="center", fontsize=11, fontweight="bold")

plt.tight_layout()
plt.show()
```

6.2. Mức độ bao phủ ID (ID Coverage)



---

7. Phân tích Mạng lưới (Network Analysis)

> **Lưu ý**: Tập `legacy` không chứa thông tin về quan hệ giữa các văn bản. Do đó, phần này chỉ được áp dụng trên tập `data`.

In [10]:
```
# === Cell 10: Phân tích Degree (Data only) ===
display(Markdown("### 7.1. Bậc kết nối (Degree Distribution) - Chỉ tập Data"))

out_deg = pl.scan_parquet(FILES["data/relationships"]).group_by("doc_id").agg(pl.le
in_deg = pl.scan_parquet(FILES["data/relationships"]).group_by("other_doc_id").agg(

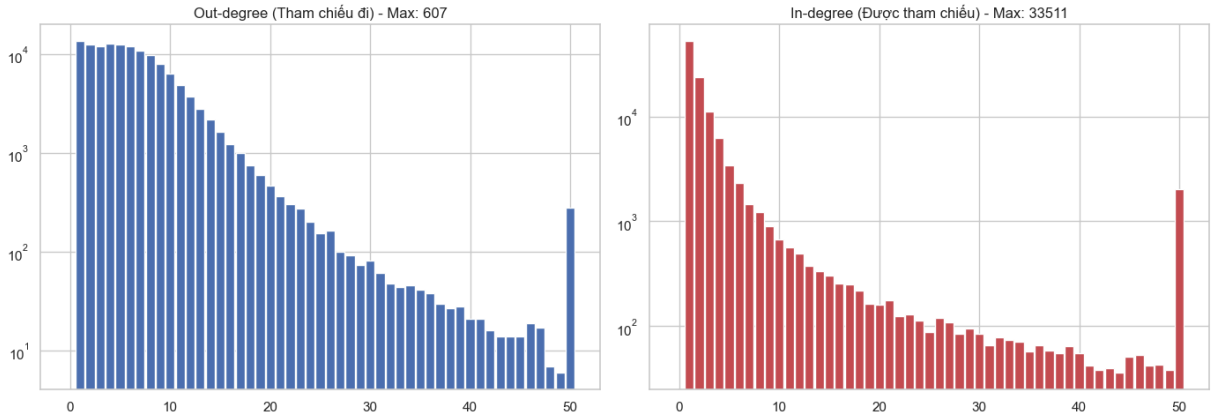
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
out_s = out_deg["out_degree"]
out_np = out_s.clip(0, 50).to_numpy()
out_bins = np.arange(0, 52)
out_hist, _ = np.histogram(out_np, bins=out_bins)
axes[0].bar(out_bins[:-1], out_hist, width=0.9, color="#4C72B0")
axes[0].set_yscale("log")
axes[0].set_title(f"Out-degree (Tham chiếu đi) - Max: {int(out_s.max())}")

in_s = in_deg["in_degree"]
in_np = in_s.clip(0, 50).to_numpy()
```

```
in_hist, _ = np.histogram(in_np, bins=out_bins)
axes[1].bar(out_bins[:-1], in_hist, width=0.9, color="#C44E52")
axes[1].set_yscale("log")
axes[1].set_title(f"In-degree (Được tham chiếu) - Max: {int(in_s.max())}")

plt.tight_layout()
plt.show()
```

7.1. Bậc kết nối (Degree Distribution) - Chỉ tập Data



---

8. Phân tích Chuyên sâu: Khoảng trống Dữ liệu (Data Gap)

In [11]:
```
# === Cell 11: Sự thiếu hụt văn bản trọng yếu ===
display(Markdown("### 8.1. Insight: 365,000+ văn bản bị rò rỉ khỏi tập `data/`"))

legacy_insights = analyze_missing_legacy_insights(FILES["data/metadata"], FILES["le

if legacy_insights["total_missing"] > 0:
    display(Markdown(f"- **Tổng số văn bản chỉ có ở legacy:** `{legacy_insights['to
    display(Markdown(f"- **Số văn bản TRỌNG YẾU bị thiếu trong data (Hiến pháp, Bộ

    fig, axes = plt.subplots(1, 2, figsize=(16, 6))

    # 1. Phân bố loại văn bản trọng yếu
    crit_df = legacy_insights["critical_counts_by_type"].to_pandas()
    axes[0].bar(crit_df["legal_type"], crit_df["count"], color="#C44E52")
    axes[0].set_title(f"449 Văn bản Trọng yếu bị thiếu", fontsize=13, fontweight="b
    for i, v in enumerate(crit_df["count"]):
        axes[0].text(i, v + max(crit_df["count"])*0.01, f"{v}", ha="center", fontsi

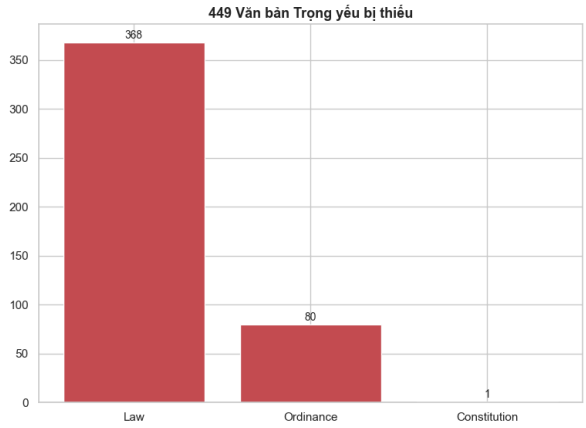
    # 2. Phân bố năm ban hành của TOÀN BỘ 365k văn bản thiếu
    year_df = legacy_insights["year_counts"].to_pandas()
    year_df = year_df[year_df["year"] > 1945].sort_values("year")
    axes[1].plot(year_df["year"], year_df["count"], marker=".", color="#4C72B0")
    axes[1].set_title("Năm ban hành của các văn bản bị thiếu", fontsize=13, fontwei
    axes[1].set_xlabel("Năm")
    axes[1].set_ylabel("Số lượng")
```

```
    plt.tight_layout()
    plt.show()

    display(Markdown("**Top 15 văn bản trọng yếu bị thiếu:**"))
    display(legacy_insights["critical_docs_sample"])
```

8.1. Insight: 365,000+ văn bản bị rò rỉ khỏi tập `data/`

- **Tổng số văn bản chỉ có ở legacy:** `402,378`
- **Số văn bản TRỌNG YẾU bị thiếu trong data (Hiến pháp, Bộ luật, Luật, Pháp lệnh):** `449`





Top 15 văn bản trọng yếu bị thiếu:

shape: (15, 5)

id	document_number	title	legal_type	issuance_date
i64	str	str	str	str
675267	"131/2025/QH15"	"Luật Sở hữu trí tuệ sửa đổi 20...	"Law"	"2025-12-10"
586814	"112/2025/QH15"	"Luật Quy hoạch 2025"	"Law"	"2025-12-10"
580594	"67/2025/QH15"	"Luật Thuế thu nhập doanh nghiệ...	"Law"	"2025-06-14"
298370	"89/2015/QH13"	"Luật thống kê 2015"	"Law"	"2015-11-23"
298374	"95/2015/QH13"	"Bộ luật hàng hải Việt Nam 2015"	"Law"	"2015-11-25"
…	…	…	…	…
588810	"37/2024/QH15"	"Luật Đấu giá tài sản sửa đổi 2...	"Law"	"2024-06-27"
667661	"105/2025/QH15"	"Luật Giám định tư pháp 2025"	"Law"	"2025-12-05"
679014	"128/2025/QH15"	"Luật Thi hành tạm giữ, tạm gia...	"Law"	"2025-12-10"
689140	"121/2025/QH15"	"Luật Hoạt động giám sát của Qu...	"Law"	"2025-12-10"
298366	"87/2015/QH13"	"Luật hoạt động giám sát của Qu...	"Law"	"2015-11-20"

---

9. Kết luận & Hướng đi

🧠 Kết luận: BẮT BUỘC Hợp nhất Data và Legacy

Qua phân tích toàn diện, chúng ta nhận thấy:

1. **Data (bản mới)**: Chứa Metadata cực kỳ chi tiết (tiếng Việt), có nội dung HTML nguyên bản, và đặc biệt là đồ thị quan hệ `relationships`.
2. **Legacy (bản cũ)**: Mặc dù schema kém chi tiết hơn, nhưng lại lưu trữ số lượng văn bản lớn hơn gấp 3 lần (518k vs 153k). Đặc biệt lưu trữ 449 văn bản nền tảng (Hiến pháp, Luật) mà tập `data` đã bỏ sót.

=> CHIẾN LƯỢC HỢP NHẤT (MERGE STRATEGY):

- **Tập nền tảng:** Sử dụng `data` làm xương sống.
- **Gộp bổ sung:** Lọc 365,000+ văn bản bị thiếu từ `legacy`, ánh xạ (map) các cột tiếng Anh sang tiếng Việt để khớp cấu trúc của `data` và gộp vào (Full Outer Join / Concat).
- Sau khi gộp, hệ thống sẽ có một "Single Source of Truth" toàn diện để phục vụ hệ thống RAG và Knowledge Graph.